Правительство Российской Федерации
Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук
Департамент программной инженерии

Дисциплина **«Алгоритмы и структуры данных»** (часть 2)

Учебный год 2015-2016, модуль 4

Домашнее задание (4 части)
Отчёт о выполненной работе

Студент: Ярных Роман Вячеславович

Группа: БПИ141 (2)

Статус представляемой работы:

Часть 1: выполнено полностью
Часть 2: выполнено полностью
Часть 3: выполнено полностью
Часть 4: не выполнена

Москва 2016

СОДЕРЖАНИЕ

1. ЧАСТЬ №1

1.1 Постановка задачи

Цель части №1 заключается в создании программы для поиска тех слов, прочитанных из файла, которые есть в исходном словаре, и тех, которые отсутствуют с использованием различных структур данных и алгоритмов и анализом эффективности их использования.

1.2 Краткий анализ задачи

Задача поиска схожих строк очень актуальна в области построения поисковых систем, анализа ДНК, нахождения грамматических ошибок и перевода текстов. Так как анализ текстов требует много времени и ресурсов для осуществления поиска строк, то необходимо изучить всевозможные алгоритмы и оценить их эффективность. В рамках данной части было реализовано четыре алгоритмы для поиска схожих строк: поиск на базе префиксных деревьев [2], поиск на базе PATRICIA деревьев [8], поиск на базе ассоциативного массива и поиск на базе хэш-таблиц [1].

Первый подход заключается в использовании хэш-таблиц [1]. Хэш-таблицы [1] представляют собой разновидность ассоциативного массива, в котором ключами являются значения хэш-функции, а в качестве значений может выступать любой тип, для которого возможно вычисление строки. Главное преимущество использования хэш-таблиц [1] заключается в том, что поиск строки в словаре занимает в среднем O(1). Библиотека STL [6] содержит реализацию контейнера на основе хэш-таблиц в виде класса unsorted_set [4]. Класс unsorted_set [4] использует закрытую адресацию для вставки, поиска и удаления значения из словаря. Однако стоит помнить, что в худшем случае сложность по времени составит O(n), если появятся коллизии. Вероятность же коллизии достаточно мала и оценивает как 1.0/std::numeric_limits<size_t>::max() [4], то есть для 32-х битных машин вероятность равна около $0.238 * 10^{-10}$, а для 64-х битных машин – $0.542 * 10^{-20}$.

Второй подход заключается в использовании ассоциативного массива, который реализуется через красно-черное дерево [7]. Красно-черные деревья [7] являются одним из видов двоичных деревьев, которые поддерживают самобалансировку. Поиск в среднем занимает O(log(n)), что хуже, чем при использовании хэш-таблиц, однако красно-черные деревья выигрывают в худшем случае, так сложность составляет O(log(n)) против O(n) у хэш-таблиц. Библиотека STL [1] содержит реализацию контейнера на базе КЧ-деревьев [7] в виде класса set.

Третий подход заключается в использовании префиксных деревьев. Префиксное дерево состоит из узлов, которые не содержат ключи, а являются метками в дереве. Поэтому любая строка по своей сути является набором меток, по котором можно пройти от корневого узла до листа. Каждый лист является пустым и служит только для того, чтобы сигнализировать о конце поиска. Сложность поиска, вставки и удаления в среднем, лучшем и худшем случае занимает O(k), где k – длина строки. Главное преимущество использования префиксных деревьев заключается в том, поиск производится достаточно быстро, причем скорость поиска не проседает на больших данных. Также важное отличие от других типов данных связано с особенностью потребления памяти. Так как префиксные деревья не хранят ключи, то по сравнению с хэш-таблицами и красно-черными деревьями они выигрывают по потреблению памяти у последних.

Четвертый подход является улучшенной версией третьего. По своей сути PATRICIA деревья [8] входят в разновидность сжатых префиксных деревьев. Сжатие достигается за счет использования строк в качестве ключей, а не отдельных символов. Данный подход позволяет уменьшить потребление памяти и ускорить процесс поиска.

Запишем сложность каждого из методов в таблицу:

Метод	В лучшем случае	В худшем случае	В среднем
Хэш-таблица	O(1)	O(n)	O(1)
Ассоциативный массива на базе деревьев	O(log(n))	O(log(n))	O(log(n))
Префиксные деревья	O(k), где k – длина слова	O(k), где k – длина слова	O(k), где k – длина слова
PATRICIA деревья	O(k), где k – длина слова	O(k), где k – длина слова	O(k), где k – длина слова

1.3 Детализации реализации

Программа состоит из нескольких программных модулей:

1. main.cpp – чтение из файла, выполнение предложенного алгоритма поиска и вывод результата в консоль или файл;
2. AbstractDictionary.h – абстрактный класс, предоставляющий интерфейс для работы с словарем;
3. HashDictionary.h – класс, реализующий словарь на базе хэш-таблиц;
4. SetDictionary.h – класс, реализующий словарь на базе ассоциативного массива;

5. TrieDictionary.h – класс. реализующий словарь на базе префиксного дерева;
6. PTrieDictionary.h – класс, реализующий словарь на базе PATRICIA дерева.

Класс AbstractDictionary и его наследники отвечают за загрузку в память словаря, поиска слов, которые присутствуют в исходном словаре, из текста, прочитанного из файла. Опишем методы и поля классов:

Dictionary	
Методы	void loadFromFile(istream&) – загружает словарь из входящего потока
	void addWord(string word) – добавляет слово в словарь
	pair<vector<string>, vector<string>> findOccurrences(istream&) – ищет все слова в файле, которые встречаются в словаре и те, которые нет
	bool isIncluded(string word) – проверяет, есть ли слово в словаре
HashDictionary	
Поля	unsorted_set<string> dict_ – словарь на базе хэш-таблицы
Методы	void loadFromFile(istream&) – загружает словарь из входящего потока
	void addWord(string word) – добавляет слово в словарь
	pair<vector<string>, vector<string>> findOccurrences(istream&) – ищет все слова в файле, которые встречаются в словаре и те, которые нет
	bool isIncluded(string word) – проверяет, есть ли слово в словаре
	HashDictionary() – конструктор
	~HashDictionary() – дескруктор
SetDictionary	
Поля	set<string> dict_ – словарь на базе ассоциативного массива
Методы	void loadFromFile(istream&) – загружает словарь из входящего потока
	void addWord(string word) – добавляет слово в словарь
	pair<vector<string>, vector<string>> findOccurrences(istream&) – ищет все слова в файле, которые встречаются в словаре и те, которые нет

	bool isIncluded(string word) – проверяет, есть ли слово в словаре
	SetDictionary() – конструктор
	~SetDictionary() – дескруктор
TrieDictionary	
Поля	Node head_ – корневой узел префиксного дерева
Методы	void loadFromFile(istream&) – загружает словарь из входящего потока
	void addWord(string word) – добавляет слово в словарь
	pair<vector<string>, vector<string>> findOccurrences(istream&) – ищет все слова в файле, которые встречаются в словаре и те, которые нет
	bool isIncluded(string word) – проверяет, есть ли слово в словаре
	TrieDictionary() – конструктор
	~TrieDictionary() – дескруктор
PTrieDictionary	
Поля	Node head_ – корневой узел PATRICIA дерева
Методы	void loadFromFile(istream&) – загружает словарь из входящего потока
	void addWord(string word) – добавляет слово в словарь
	pair<vector<string>, vector<string>> findOccurrences(istream&) – ищет все слова в файле, которые встречаются в словаре и те, которые нет
	bool isIncluded(string word) – проверяет, есть ли слово в словаре
	PTrieDictionary() – конструктор
	~PTrieDictionary() – дескруктор

Покажем взаимосвязь классов в программе с помощью UML диаграммы:

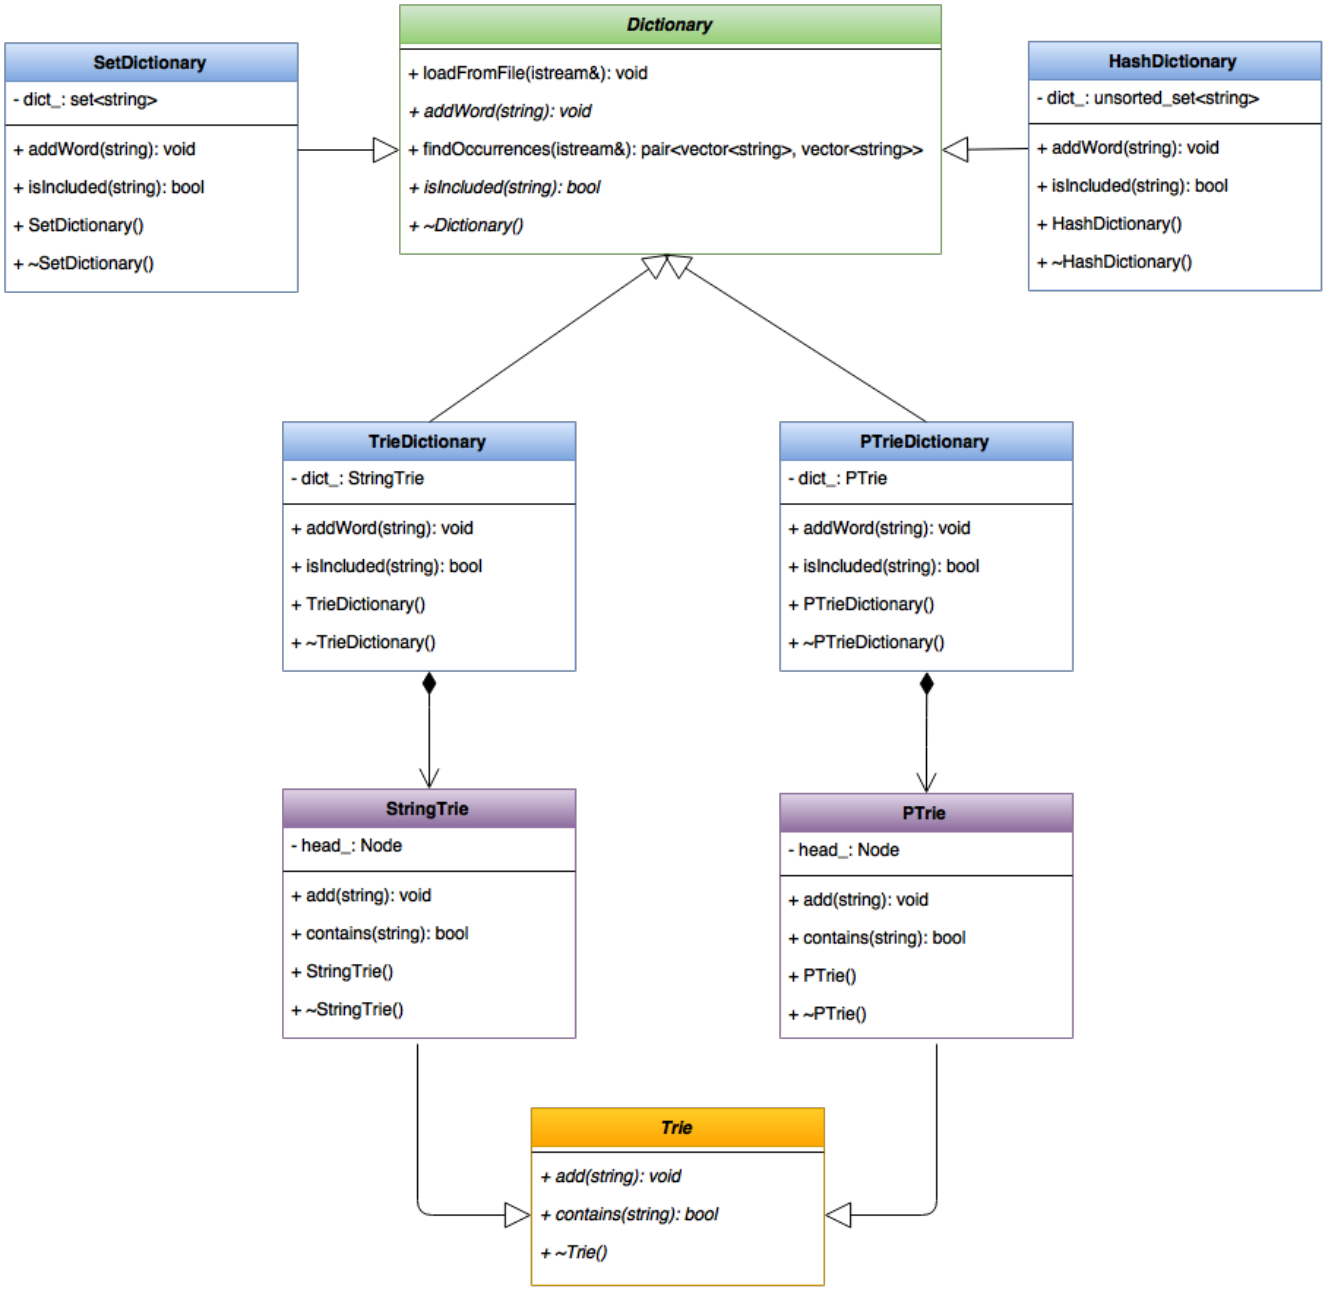

Приведем исходные коды реализации. Исходный код класса Dictionary:

```
#pragma once
#ifndef CHW_2_ABSTRACTDICTIONARY_H
#define CHW_2_ABSTRACTDICTIONARY_H

#include <iostream>
#include <vector>

using namespace std;

class Dictionary {
public:
```

```
    virtual void loadDictFromFile(istream& input);
    virtual void addWord(string word) = 0;
    virtual pair<vector<string>, vector<string>> findOccurrences(istream& input);
    virtual bool isIncluded(string word) = 0;
    virtual ~Dictionary() = 0;
};

void Dictionary::loadDictFromFile(istream &input) {
    string temp_;
    while(getline(input, temp_)){
        addWord(temp_);
    }
}

pair<vector<string>, vector<string>> Dictionary::findOccurrences(istream &input) {
    string temp_;
    vector<string> occurrences_;
    vector<string> notIncluded_;
    while(input >> temp_){
        stringstream ss;
        bool lastNonAlpha = false;
        for(string::iterator it = temp_.begin(); it != temp_.end(); it++){
            if((*it < 'a' || *it > 'z') && !lastNonAlpha) {
                string word_ = ss.str();
                if (isIncluded(word_)) {
                    occurrences_.push_back(word_);
                }
                else{
                    notIncluded_.push_back(word_);
                }
                ss.str("");
                lastNonAlpha = true;
            }
            else if(isalpha(*it)){
                lastNonAlpha = false;
                ss << (*it);
            }
        }
        if(ss.str().size() > 0){
            string word_ = ss.str();
            if (isIncluded(word_)) {
                occurrences_.push_back(word_);
            }
            else{
                notIncluded_.push_back(word_);
```

```
            }
        }
    }
    return pair<vector<string>, vector<string>>(occurrences_, notIncluded_);
}

Dictionary::~Dictionary(){

}

#endif //CHW_2_ABSTRACTDICTIONARY_H
```

Исходный код класса HashDictionary:

```
#pragma once

#ifndef CHW_2_HASHDICTIONARY_H
#define CHW_2_HASHDICTIONARY_H

#include <unordered_set>
#include <sstream>
#include <set>
#include <map>
#include "IDictionary.h"

/*
 * Dictionary based on hash tables
 */
class HashDictionary : public IDictionary {
public:
    void addWord(string word);
    bool isIncluded(string word);
    set<string> getWords();
    HashDictionary();
    virtual ~HashDictionary();
private:
    unordered_set<string> *dict_;
};

/*
 * Add word to dictionary
 */
void HashDictionary::addWord(string word) {
    dict_->insert(word);
```

```
}

/*
 * Check if word exists in dictionary
 */
bool HashDictionary::isIncluded(string word){
    return dict_->find(word) != dict_->end();
}

/*
 * Retrieve all words from dictionary
 */
set<string> HashDictionary::getWords() {
    set<string> words_;
    for(unordered_set<string>::iterator it = dict_->begin(); it != dict_->end(); it++)
        words_.insert(*it);
    return words_;
}

/*
 * Construct an instance of dictionary
 */
HashDictionary::HashDictionary() {
    dict_ = new unordered_set<string>();
}

/*
 * Delete instance of dictionary
 */
HashDictionary::~HashDictionary() {
    delete dict_;
}

#endif //CHW_2_HASHDICTIONARY_H
```

Исходный код класса SetDictionary:

```
#pragma once

#ifndef CHW_2_SETDICTIONARY_H
#define CHW_2_SETDICTIONARY_H

#include <set>
#include "IDictionary.h"
```

```
/*
 * Dictionary based on red-n-black trees
 */
class SetDictionary : public IDictionary {

public:

    virtual void addWord(string word);

    virtual bool isIncluded(string word);

    virtual set<string> getWords();

    SetDictionary();

    virtual ~SetDictionary();

private:

    set<string> *dict_;
};

/*
 * Add word to dictionary
 */
void SetDictionary::addWord(string word) {
    dict_->insert(word);
}

/*
 * Check if word exists in dictionary
 */
bool SetDictionary::isIncluded(string word) {
    return dict_->find(word) != dict_->end();
}

/*
 * Retrieve all words from dictionary
 */
set<string> SetDictionary::getWords() {
    return set<string>(*dict_);
}

/*
 * Construct an instance of dictionary
```

```
 */
SetDictionary::SetDictionary() {
    dict_ = new set<string>;
}

/*
 * Delete instance of dictionary
 */
SetDictionary::~SetDictionary() {
    delete dict_;
}

#endif //CHW_2_SETDICTIONARY_H
```

Исходный код класса TrieDictionary:

```
#pragma once

#ifndef CHW_2_TRIEDICTIONARY_H
#define CHW_2_TRIEDICTIONARY_H

#include "IDictionary.h"
#include "../tree/Trie.h"

/*
 * Dictionary based on prefix trees
 */
class TrieDictionary : public IDictionary {

public:
    virtual set<string> getWords();

    void addWord(string word);

    bool isIncluded(string word);

    TrieDictionary();

    virtual ~TrieDictionary();

private:
    Trie *trie_;
};
```

```
/*
 * Add word to dictionary
 */
void TrieDictionary::addWord(string word) {
    trie_->add(word);
}

/*
 * Check if word exists in dictionary
 */
bool TrieDictionary::isIncluded(string word) {
    return trie_->contains(word);
}

/*
 * Retrieve all words from dictionary
 */
set<string> TrieDictionary::getWords() {
    return set<string>();
}

/*
 * Construct an instance of dictionary
 */
TrieDictionary::TrieDictionary() {
    trie_ = new Trie;
}

/*
 * Delete instance
 */
TrieDictionary::~TrieDictionary() {
    delete trie_;
}

#endif //CHW_2_TRIEDICTIONARY_H
```

Исходный код класса Trie:

```
#pragma once

#ifndef CHW_2_TRIE_H
#define CHW_2_TRIE_H
#define ALPH_N 26
```

```
#include <set>
#include "ITree.h"

/*
 * Prefix tree (trie)
 */
class Trie : public ITree<string> {
private:
    struct Node{
        char key;
        Node* children[ALPH_N];
    };
    Node *head_;

public:
    void add(string key);
    bool contains(string key);
    Trie();
    virtual ~Trie();

private:
    void _clear(Node* node);
};

/*
 * Construct an instance of trie
 */
Trie::Trie() {
    head_ = new Node;
}

/*
 * Add key into tree
 */
void Trie::add(string key) {
    Node* temp_ = head_;
    for(string::iterator it = key.begin(); it != key.end(); it++){
        Node* child_ = temp_->children[*it - 'a'];
        if(!child_){
            child_ = new Node;
            child_->key = *it;
            temp_->children[*it - 'a'] = child_;
        }
        temp_ = child_;
    }
```

```
}

/*
 * Check if key exists in tree
 */
bool Trie::contains(string key) {
    bool inc_ = true;
    Node *temp_ = head_;
    for(string::iterator it = key.begin(); it != key.end(); it++){
        if(!temp_->children[*it - 'a']){
            inc_ = false;
            break;
        }
        else{
            temp_ = temp_->children[*it - 'a'];
        }
    }
    return inc_;
}

/*
 * Clear tree
 */
void Trie::_clear(Node* node){
    if(!node)
        return;
    for(int i = 0; i < ALPH_N; i++){
        if(!node->children[i]) {
            _clear(node->children[i]);
            delete node->children[i];
        }
    }
}

/*
 * Delete instance
 */
Trie::~Trie() {
    Node* temp_ = head_;
    _clear(temp_);
}

#endif //CHW_2_TRIE_H
```

Исходный код класса PTrie:

```
#pragma once

#ifndef CHW_2_PTREEDICTIONARY_H
#define CHW_2_PTREEDICTIONARY_H

#include <set>
#include "IDictionary.h"
#include "../tree/PTrie.h"

/*
 * Compressed radix (prefix) tree
 */
class PTrieDictionary : public IDictionary {

public:

    virtual set<string> getWords();

    PTrieDictionary();
    virtual void addWord(string word);

    virtual bool isIncluded(string word);

    virtual ~PTrieDictionary();

private:
    PTrie *trie_;
};

/*
 * Construct an instance of PATRICIA trie
 */
PTrieDictionary::PTrieDictionary() {
    trie_ = new PTrie;
}

/*
 * Add word to dictionary
 */
void PTrieDictionary::addWord(string word) {
    trie_->add(word);
}

/*
```

```
 * Check if word exists in dictionary
 */
bool PTrieDictionary::isIncluded(string word) {
    return trie_->contains(word);
}

/*
 * Retrieve all words from dictionary
 */
set<string> PTrieDictionary::getWords() {
    return set<string>();
}

/*
 * Delete instance
 */
PTrieDictionary::~PTrieDictionary() {
    delete trie_;
}

#endif //CHW_2_PTREEDICTIONARY_H
```

Исходный код класса PTrie:

```
#pragma once

#ifndef CHW_2_PTRIE_H
#define CHW_2_PTRIE_H

#include "ITree.h"
#include "PTNode.h"

/*
 * PATRICIA trie
 */
class PTrie : public ITree<string>{
private:
    PTNode *head_;

public:
    virtual void add(string key);
    virtual bool contains(string key);
    virtual ~PTrie();

private:
```

```
    void _clear(PTNode * node);
    PTNode * _find(PTNode * node, string str);
    unsigned long _prefixLen(string s1, string s2);
    PTNode * _insert(PTNode * node, string str);
    void _cutNode(PTNode * node, unsigned long index);
};

/*
 * Add key into tree
 */
void PTrie::add(string key) {
    head_ = _insert(head_, key);
}

/*
 * Check if key exists in tree
 */
bool PTrie::contains(string key) {
    return _find(head_, key) != nullptr;
}

/*
 * Clear tree
 */
void PTrie::_clear(PTNode *node) {
    if(!node)
        return;
    PTNode * olderChild = node->olderChild;
    _clear(olderChild);
    PTNode * sister = node->sister;
    delete node;
    _clear(sister);
}

/*
 * Find node with specific key
 */
PTNode * PTrie::_find(PTNode *node, string str){
    if(!node)
        return nullptr;
    unsigned long pfl_ = _prefixLen(str, node->key);
    if(pfl_ == str.length())
        return node;
    else if(!pfl_)
        return _find(node->sister, str);
```

```
    else if(pfl_ == node->key.length())
        return _find(node->olderChild, str.substr(pfl_, str.length() - pfl_));
    return nullptr;
}

/*
 * Compute length of largest common prefix
 */
unsigned long PTrie::_prefixLen(string s1, string s2) {
    for(unsigned long k = 0; k < s1.length(); k++)
        if(k == s2.length() || (s1[k] != s2[k]))
            return k;
    return s1.length();
}

/*
 * Insert a node into tree
 */
PTNode * PTrie::_insert(PTNode *node, string str) {
    if(!node)
        return new PTNode(str, nullptr, nullptr);
    unsigned long pfl_ = _prefixLen(str, node->key);
    if(pfl_ == 0)
        node->sister = _insert(node->sister, str);
    else if(pfl_ < str.length()){
        if(pfl_ < node->key.length())
            _cutNode(node, pfl_);
        node->olderChild = _insert(node->olderChild, str.substr(pfl_, str.length() - pfl_));
    }
    return node;
}

/*
 * Split node into two new ones
 */
void PTrie::_cutNode(PTNode *node, unsigned long index) {
    PTNode *newChild_ = new PTNode(node->key.substr(index, node->key.length() -
index), nullptr, node->olderChild);
    node->key = node->key.substr(0, index);
    node->olderChild = newChild_;
}

/*
 * Delete instance
 */
```

```
PTrie::~PTrie() {
    _clear(head_);
}

#endif //CHW_2_PTRIE_H
```

1.4 Дополнительная функциональность

Дополнительная функциональность реализации отсутствует.

1.5 Заключение

В рамках первой части нами было проведена оценка эффективности работы предложенных методов с помощью теоретического математического аппарата теории алгоритмов и разработана программа, решающая поставленные задачи с использованием этих методов.

Было выявлено, что все три метода, а именно префиксные деревья, красно-черные деревья и PATRICIA деревья, работают во всех случаях за одно время. В противоположенность этому хэш-таблицы ввиду ненулевой вероятности возникновения коллизий могут привести к ухудшению сложности. Однако вероятность возникновения коллизии достаточно мала. Согласно официальной документации по unordered_set вероятность коллизии составляет 1.0/std::numeric_limits<size_t>::max(), то есть для 32-х битных машин вероятность равна около $0.238 * 10^{-10}$, а для 64-х битных машин – $0.542 * 10^{-20}$.

2. ЧАСТЬ №2

2.1 Постановка задачи

Цель части №2 заключается в написании программного кода для оценки эффективности использования различных комбинаций контейнеров и алгоритмов для поиска слов, отличных на один символ и имеющих один и тот же размер.

2.2 Краткий анализ задачи

В соответствии с целью были поставлены следующие задачи:

1. разработать алгоритмы (методы) для поиска слов, отличающихся на один символ;
2. оценить эффективность использованных алгоритмов и контейнеров;
3. сделать выводы по поводу использования данных алгоритмов на практике.

Для решения поставленных задач было разработано три метода поиска слов:

1. наивный поиск с использованием std::map<string, vector<string>>;
2. улучшенный поиск с использованием std::map<string, vector<string>> и предварительной группировкой слов по их длине;
3. поиск с предварительной группировкой слов по длине, а также по общему префиксу и суффиксу.

Первый метод заключается в наивном поиске слов, путем прохода по всему массиву и сравниванию одного слова с другим. В случае, если одно слово может быть получено путем изменения буквы в другом, то для первого в список заносится второе. Данный метод имеет сложность в лучшем худшем и среднем случаях $O(n^2)$, что является, несомненно, самым плохим вариантом поиска.

Второй метод имеет асимптотически такую же сложность, что и первый, но при его использовании улучшается коэффициент при n^2 за счет уменьшения числа сравнений путем группировки слов по длине. При таком методе слова сравниваются только в своей группе и имеют одну и ту же длину, что позволяет не производить заведомо лишние сравнения. В общем, сложность второго подхода равна $O(n) + O(n^2) = O(n^2)$, где $O(n)$ – время группировки слов по длине. Также важно отметить, что для второго метода требуется $O(n)$ дополнительной памяти.

Третий вариант улучшает изначальный наивный поиск с помощью группировки слов не только по размеру, но и общему префиксу и суффиксу. Если для группировки слов с общим префиксом и суффиксом используется std::set<string>, то сложность по времени в худшем, лучшем и среднем случае составит

$O(log(n) * max(k))$, где k – размер префиксного или суффиксного массива. Заметим, что если все слова имеют один префикс или суффикс, при условии $max(k) \leq n$, то $max(k) = n$, следовательно, сложность метода составит $O(log(n) * n)$. При использовании std::unordered_set<string> сложность метода в лучшем и среднем случае составит $O(n)$, в худшем – $O(n^2)$. Как и во втором методе, потребуется $O(n)$ дополнительной памяти.

2.3 Детализации реализации

Было решено перенести функциональность поиска схожих строк в новые классы, не входящие в иерархию классов, ответственных за реализацию работы словарей. С этой целью были разработаны классы FuzzySearcher, NaiveSearcher, OptNaiveSearcher и QuickSearcher. Вершиной иерархии выступает FuzzySearcher, определяющий интерфейс методов для конечного клиента. Классы NaiveSearcher, OptNaiveSearcher и QuickSearcher реализует каждый из предложенных 3 методов. Опишем структуру классов:

FuzzySearcher	
Поля	set<string> *dict_ – исходный словарь
Методы	FuzzySearcher() – конструктор по умолчанию
	FuzzySearcher(set<string>) – конструктор, принимающий в качестве аргумента исходный словарь
	~FuzzySearcher() – деструктор
	map<string, set<string>> fuzzySearch() – поиск строк, отличных на один символ
	bool _areDifferentByOneSym(string, string) – сравнение строк
	string _getPrefix(string) – получение префикса строки
	string _getSuffix(string) – получение суффикса строки
NaiveSearcher	
Поля	set<string> *dict_ – исходный словарь
Методы	NaiveSearcher() – конструктор по умолчанию
	NaiveSearcher(set<string>) – конструктор, принимающий в качестве аргумента исходный словарь
	~NaiveSearcher() – деструктор
	map<string, set<string>> fuzzySearch() – поиск строк, отличных на один символ

	bool _areDifferentByOneSym(string, string) – сравнение строк
	string _getPrefix(string) – получение префикса строки
	string _getSuffix(string) – получение суффикса строки
OptNaiveSearcher	
Поля	set<string> *dict_ – исходный словарь
Методы	OptNaiveSearcher() – конструктор по умолчанию
	OptNaiveSearcher(set<string>) – конструктор, принимающий в качестве аргумента исходный словарь
	~OptNaiveSearcher() – деструктор
	map<string, set<string>> fuzzySearch() – поиск строк, отличных на один символ
	bool _areDifferentByOneSym(string, string) – сравнение строк
	string _getPrefix(string) – получение префикса строки
	string _getSuffix(string) – получение суффикса строки
QuickSearcher	
Поля	set<string> *dict_ – исходный словарь
Методы	QuickSearcher() – конструктор по умолчанию
	QuickSearcher(set<string>) – конструктор, принимающий в качестве аргумента исходный словарь
	~QuickSearcher() – деструктор
	map<string, set<string>> fuzzySearch() – поиск строк, отличных на один символ
	bool _areDifferentByOneSym(string, string) – сравнение строк
	string _getPrefix(string) – получение префикса строки
	string _getSuffix(string) – получение суффикса строки

Покажем отношения между классами с помощью UML диаграмм:

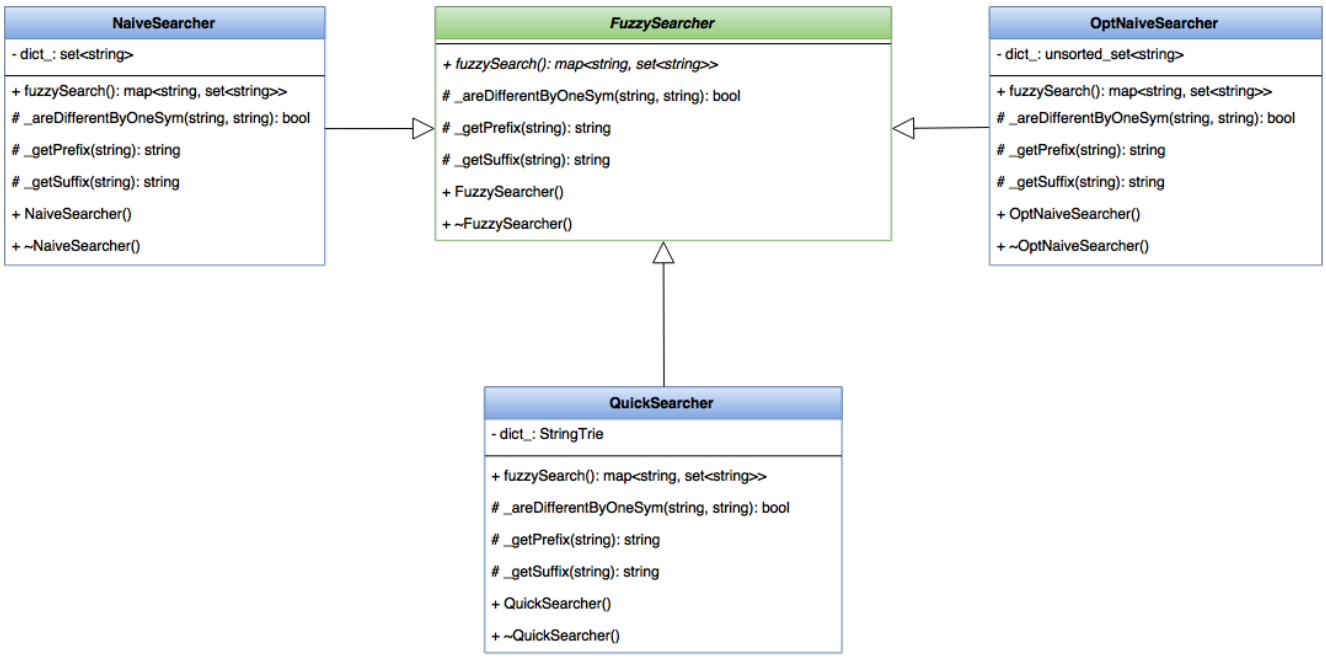

Приведем исходные коды классов. Исходный код класса FuzzySearcher:

```
#pragma once
#ifndef CHW_2_FUZZYSEARCHER_H
#define CHW_2_FUZZYSEARCHER_H


#include <iostream>
#include <string>
#include <set>

using namespace std;

class FuzzySearcher {
public:
    FuzzySearcher();
    FuzzySearcher(set<string> ws);
    virtual ~FuzzySearcher();
    virtual map<string, set<string>> fuzzySearch() = 0;

protected:
    int _hamming_distance(string a, string b);
    bool _areDifferentByOneSym(string a, string b);
    string _getPrefix(string s);
    string _getSuffix(string s);
    set<string> *dict_;
};
```

```
FuzzySearcher::FuzzySearcher() {

}

FuzzySearcher::FuzzySearcher(set<string> ws) {
    dict_ = new set<string>(move(ws));
}

FuzzySearcher::~FuzzySearcher() {
    delete dict_;
}

int FuzzySearcher::_hamming_distance(string a, string b) {
    const char* a_ = a.c_str();
    const char* b_ = b.c_str();
    int d_ = 0;
    for(int i = 0; i < a.length(); i++){
        d_ += ((a_[i] - b_[i]) == 0 ? 0 : 1);
    }
    return d_;
}

bool FuzzySearcher::_areDifferentByOneSym(string a, string b) {
    bool dif_ = false;
    for(int i = 0; i < a.length(); i++){
        if(a[i] != b[i]){
            if(dif_) {
                dif_ = false;
                break;
            }
            else
                dif_ = true;
        }
    }
    return dif_;
}

string FuzzySearcher::_getPrefix(string s) {
    int prefixEnd_ = (int)floor(s.length() / 2);
    return s.substr(0, (unsigned long)prefixEnd_ + 1);
}

string FuzzySearcher::_getSuffix(string s) {
    int prefixEnd_ = (int)floor(s.length() / 2);
    return s.substr((unsigned long)prefixEnd_ + 1, s.length() - prefixEnd_ - 1);
```

```
}


#endif //CHW_2_FUZZYSEARCHER_H
```

Исходный код NaiveSearcher:

```
#ifndef CHW_2_NAIVYSEARCHER_H
#define CHW_2_NAIVYSEARCHER_H


#include "FuzzySearcher.h"
#include <map>

class NaiveSearcher : public FuzzySearcher{

public:
    NaiveSearcher(set<string> s) : FuzzySearcher(s){}
    virtual map<string, set<string>> fuzzySearch();
};


#endif //CHW_2_NAIVYSEARCHER_H

map<string, set<string>> NaiveSearcher::fuzzySearch() {
    map<string, set<string>> fsmw_;
    for(auto it = dict_->begin(); it != dict_->end(); it++){
        set<string> mw_;
        string current_ = *it;
        for(auto it1 = dict_->begin(); it1 != dict_->end(); it1++){
            string other_ = *it1;
            if(other_.length() != current_.length())
                continue;
            if(_areDifferentByOneSym(current_, other_))
                mw_.insert(other_);
        }
        fsmw_.insert(pair<string, set<string>>(current_, mw_));
    }
    return fsmw_;
}
```

Исходный код OptNaiveSearcher:

```
#ifndef CHW_2_OPTNAIVESEARCHER_H
#define CHW_2_OPTNAIVESEARCHER_H
```

```
#include "FuzzySearcher.h"
#include <map>

class OptNaiveSearcher : public FuzzySearcher{

public:
    OptNaiveSearcher(set<string> s) : FuzzySearcher(s){}
    virtual map<string, set<string>> fuzzySearch();
};


#endif //CHW_2_OPTNAIVESEARCHER_H

map<string, set<string>> OptNaiveSearcher::fuzzySearch() {
    map<string, set<string>> fsmw_;
    map<unsigned long, set<string>> lg_;
    for(auto it = dict_->begin(); it != dict_->end(); it++){
        if(lg_.find(it->length()) != lg_.end()){
            lg_[it->length()].insert(*it);
        }
        else{
            set<string> clws_;
            clws_.insert(*it);
            lg_.insert(pair<unsigned long, set<string>>(it->length(), clws_));
        }
    }
    for(auto lg_it = lg_.begin(); lg_it != lg_.end(); lg_it++){
        for(set<string>::iterator word_ = lg_it->second.begin(); word_ != lg_it-
>second.end(); word_++){
            set<string> mw_;
            for(set<string>::iterator oword_ = lg_it->second.begin(); oword_ != lg_it-
>second.end(); oword_++){
                if(_areDifferentByOneSym(*word_, *oword_))
                    mw_.insert(*oword_);
            }
            fsmw_.insert(pair<string, set<string>>(*word_, mw_));
        }
    }
    return fsmw_;
}
```

Исходный код QuickSearcher:

```
#ifndef CHW_2_QUICKSEARCHER_H
#define CHW_2_QUICKSEARCHER_H

#include "FuzzySearcher.h"
#include <map>
#include <unordered_set>
#include <unordered_map>

class QuickSearcher : public FuzzySearcher{

public:
    QuickSearcher(set<string> s) : FuzzySearcher(s) {}
    virtual map<string, set<string>> fuzzySearch();
};


#endif //CHW_2_QUICKSEARCHER_H

map<string, set<string>> QuickSearcher::fuzzySearch() {
    map<string, set<string>> fsmw_;
    map<unsigned long, set<string>> lg_;
    for(auto it = dict_->begin(); it != dict_->end(); it++){
        if(lg_.find(it->length()) != lg_.end()){
            lg_[it->length()].insert(*it);
        }
        else{
            set<string> clws_;
            clws_.insert(*it);
            lg_.insert(pair<unsigned long, set<string>>(it->length(), clws_));
        }
    }
    for(auto lg_it = lg_.begin(); lg_it != lg_.end(); lg_it++){
        unordered_map<string, unordered_set<string>> prefixMap_;
        unordered_map<string, unordered_set<string>> suffixMap_;
        for(auto word_ = lg_it->second.begin(); word_ != lg_it->second.end(); word_++){
            string prefix_ = _getPrefix(*word_);
            string suffix_ = _getSuffix(*word_);
            if(prefixMap_.find(prefix_) != prefixMap_.end()){
                prefixMap_[prefix_].insert(suffix_);
            }
            else{
                prefixMap_[prefix_] = unordered_set<string>();
            }

            if(suffixMap_.find(suffix_) != suffixMap_.end()){
```

```
            suffixMap_[suffix_].insert(prefix_);
        }
        else{
            suffixMap_[suffix_] = unordered_set<string>();
        }
    }
    for(auto word_ = lg_it->second.begin(); word_ != lg_it->second.end(); word_++){
        set<string> mw_;
        string ownPrefix_ = _getPrefix(*word_);
        string ownSuffix_ = _getSuffix(*word_);
        unordered_set<string> sufs_ = prefixMap_[ownPrefix_];
        unordered_set<string> prefs_ = suffixMap_[ownSuffix_];
        for(auto suf_ = sufs_.begin(); suf_ != sufs_.end(); suf_++){
            if(_areDifferentByOneSym(ownSuffix_, *suf_))
                mw_.insert(ownPrefix_ + (*suf_));
        }
        for(auto pref_ = prefs_.begin(); pref_ != prefs_.end(); pref_++){
            if(_areDifferentByOneSym(ownPrefix_, *pref_))
                mw_.insert((*pref_) + ownSuffix_);
        }
        fsmw_.insert(pair<string, set<string>>(*word_, mw_));
    }
  }
  return fsmw_;
}
```

2.4 Дополнительная функциональность

Дополнительная функциональность реализации отсутствует.

2.5 Заключение

Во второй части нами было иследовано влияния комбинации различных контейнеров для решения поставленной задачи на эффективность поиска. Первый метод оказался наиболее неэффективным в плане скорости работы, так как время работы является квадратичной, поэтому его целесообразно использовать на словарях меньшего размера. Другой метод является логическим следствием первого, но с некоторыми улучшениями, однако данные улучшения не меняют асимптотическую сложность метода. Третий подход оказался самым эффективным и его асимптотическая сложность стремится к $O(log(n) * n)$, что позволяет использовать данный метод на практике. За ускорение по времени необходимо платить дополнительной памятью.

3. ЧАСТЬ №3

3.1 Постановка задачи

Цель части №3 разработать методы для поиска ошибочных слов и вариантов их замены путем удаления одного символа, вставки одного символа и транспозиции букв в строке, разработать программу для реализации методов и оценить их эффективность.

3.2 Краткий анализ задачи

Поиск слов, написанных с ошибкой, и вариантов их исправления является неотъемлемой частью системы проверки орфография современных программ для редактирования документов. В соответствии с предложенной проблемой были поставлены следующие задачи:

1. разработать методы для поиска ошибочных слов в тексте и вариантов их исправления путем преобразований через вставку или удаления одного символа, либо транспозицию букв внутри строки;
2. написать программу, реализующие данные методы;
3. оценить эффективность использования данных методов;
4. сделать выводы по поводу использования данных методов на практике.

Перед тем, как находить ошибки в тексте, необходимо составить словарь, включающие эталонные слова для проверки орфографии. Словарь целесообразно хранить в тех структурах данных, которые позволяют сократить время поиска до максимума. В нашей реализации было решено использовать хэш-таблицы, так как они обеспечивают в большинстве случаев линейную сложность поиска. В редких случаях возможно возникновение коллизий, которые приводят к тому, что время поиска уже не линейно, а квадратично. Но в среднем время поиска в хэш-таблице лучшем, чем в красно-черных деревьях, чья сложность поиска составляет $O(log(n))$.

При сканировании текста, программа ищет слово в словаре и если его не находит, что фиксирует это слово как ошибочное, сохраняет его номер, а затем производит поиск вариантов замены. Замена может быть произведена либо через удаление одного символа из исходного слова или вставки в него символа, либо через транспозицию букв.

Первый метод производит поиск все тех слов в словаре, которые могут быть получены путем перестановки (транспозиции) букв в исходном слове. Наивный поиск даст нам сложность $O(n^2)$, что не приемлемо для работы с большим текстом и словарем, поэтому необходимо снизить сложность до приемлемого

уровня. Снизить сложность можно путем предварительной группировки слов по длине и общему набору символов, входящих в эти слова. Транспозиция обладает таким свойством, что слова одинаковой длины и отличные лишь перестановкой символов имеют одинаковый набор символов, входящих в них. Распишем последовательность шагов выбранного метода:

1. загружаем словарь из исходного файла;
2. группируем слова по длине строки;
3. в каждой группе разбиваем слова на новые группы (ассоциативными массивами), ключами которых являются отсортированная последовательность символов исходных строк, а значения – сами строки;
4. для проверяемого слова вычисляем длину строки;
5. длина строки позволит нам найти нужную группу слов, в которых мы и будем выбирать варианты замены;
6. в найденной группе находим слова, которые имеют тот же набор символов, что и проверяемое слово;
7. эти слова и будут вариантами замены.

Оценим сложность данного метода. Группировка слов по длине занимает $O(n)$. Группировка по набору символов занимает также $O(n)$. Поиск вариантов замены имеет сложность в лучшем и среднем случае $O(n)$, если используются хэш-таблицы, в худшем случае – $O(n^2)$. Если же используются красно-черные деревья [6], то сложность составляет в лучшем, среднем и худшем случае $O(log(n) * n)$.

3.3 Детализации реализации

Для реализации разработанных методов был написан класс SpellSearcher, который отвечает за проверку слова на предмет орфографической ошибки и вариантов замены. Опишем структуру класса:

SpellSearcher	
Поля	set<string> *dict_ – исходный словарь
	unordered_map<unsigned long, unordered_map<string, unordered_ser<string>>> ltg_ – группа слов с одинаковой длиной и набором букв
Методы	SpellChecker() – конструктор
	~SpellChecker() – деструктор
	void loadDictionary(istream&) – загрузка словаря из входного потока
	set<string> options_T(string) – поиск вариантов замены через транспозицию

	set<string> options_D(string) – поиск вариантов замены через удаление символа
	set<string> options_I(string) – поиск замены через вставку символа
	bool spellCheck(string) – проверка на предмет наличия орфографической ошибки

Приведем исходный код класса SpellChecker:

```
#pragma once

#ifndef CHW_2_SPELLCHECKER_H
#define CHW_2_SPELLCHECKER_H
#include <string>
#include <set>
#include <unordered_map>
#include <unordered_set>

using namespace std;

typedef unordered_map<string, unordered_set<string>> PREFIX_MAP;
typedef unordered_map<string, unordered_set<string>> SUFFIX_MAP;
typedef unsigned long ULONG;
typedef unordered_set<string> STRING_SET;
typedef unordered_set<string>::iterator SSET_ITERATOR;

/**
 * Implementation of spell checking
 * with search options for replace wrong words by right ones
 */
class SpellChecker {
public:
    SpellChecker();
    virtual ~SpellChecker();
    void loadDictionary(istream& input);
    set<string> options_T(string s);
    set<string> options_D(string s);
    set<string> options_I(string s);
    bool spellCheck(string s);
private:
    set<string> *dict_;
    unordered_map<ULONG, unordered_map<string, unordered_set<string>>> ltg_;
    unordered_map<ULONG, pair<PREFIX_MAP, SUFFIX_MAP>> lpg_;
```

```
    void _initLTG();
    void _initLPSG();
    string _getPrefix(string s);
    string _getSuffix(string s);
};

/*
 * Construct an instance of dictionary
 */
SpellChecker::SpellChecker(){
    dict_ = new set<string>();
}

/*
 * Delete instance
 */
SpellChecker::~SpellChecker() {
    delete dict_;
}

/*
 * Load dictionary from input stream (file)
 */
void SpellChecker::loadDictionary(istream &input) {
    string temp_;
    while(getline(input, temp_)){
        dict_->insert(temp_);
    }
    _initLTG();
    _initLPSG();
}

/*
 * Check if word is wrong
 */
bool SpellChecker::spellCheck(string s) {
    return dict_->find(s) != dict_->end();
}

/*
 * Find all options for replace wrong word by right ones
 * which can be transformed into verifiable word through transposition
 * neighborhood in source word
 */
set<string> SpellChecker::options_T(string s) {
```

```
    sort(s.begin(), s.end());
    return set<string>(ltg_[s.length()][s].begin(), ltg_[s.length()][s].end());
}

/*
 * Find all options for replace wrong word by right ones
 * which can be transformed into verifiable word through deletion one symbol
 * from source word
 */
set<string> SpellChecker::options_D(string s) {
    set<string> cw_;
    string prefix_ = _getPrefix(s);
    string suffix_ = _getSuffix(s);
    PREFIX_MAP prefix_map = lpg_[s.length() + 1].first;
    SUFFIX_MAP suffix_map = lpg_[s.length() + 1].second;
    STRING_SET suffixes_ = prefix_map[prefix_];
    STRING_SET prefixes_ = suffix_map[suffix_];
    for(auto s_ = suffixes_.begin(); s_ != suffixes_.end(); s_++){
        cw_.insert(prefix_ + *s_);
    }
    for(auto p_ = prefixes_.begin(); p_ != prefixes_.end(); p_++){
        cw_.insert(*p_ + suffix_);
    }
    return cw_;
}

/*
 * Find all options for replace wrong word by right ones
 * which can be transformed into verifiable word through insertion one symbol
 * into source word
 */
set<string> SpellChecker::options_I(string s) {
    set<string> cw_;
    string prefix_ = _getPrefix(s);
    string suffix_ = _getSuffix(s);
    PREFIX_MAP prefix_map = lpg_[s.length() - 1].first;
    SUFFIX_MAP suffix_map = lpg_[s.length() - 1].second;
    STRING_SET suffixes_ = prefix_map[prefix_];
    STRING_SET prefixes_ = suffix_map[suffix_];
    for(auto s_ = suffixes_.begin(); s_ != suffixes_.end(); s_++){
        cw_.insert(prefix_ + *s_);
    }
    for(auto p_ = prefixes_.begin(); p_ != prefixes_.end(); p_++){
        cw_.insert(*p_ + suffix_);
    }
```

```
    return cw_;
}


void SpellChecker::_initLTG(){
    for(auto w_ = dict_->begin(); w_ != dict_->end(); w_++){
        if(ltg_.find(w_->length()) == ltg_.end()){
            ltg_[w_->length()] = unordered_map<string, unordered_set<string>>();
        }
        string temp_(*w_);
        sort(temp_.begin(), temp_.end());
        if(ltg_[w_->length()].find(temp_) == ltg_[w_->length()].end()){
            ltg_[w_->length()][temp_] = unordered_set<string>();
        }
        ltg_[w_->length()][temp_].insert(*w_);
    }
}

void SpellChecker::_initLPSG() {
    for(auto w_ = dict_->begin(); w_ != dict_->end(); w_++){
        if(lpg_.find(w_->length()) == lpg_.end()){
            lpg_[w_->length()] = pair<PREFIX_MAP, SUFFIX_MAP>();
        }
        string prefix_ = _getPrefix(*w_);
        string suffix_ = _getSuffix(*w_);
        if(w_->length() % 2){
            if(lpg_[w_->length()].first.find(prefix_) == lpg_[w_->length()].first.end())
                lpg_[w_->length()].first[prefix_] = unordered_set<string>();
            if(lpg_[w_->length()].second.find(suffix_) == lpg_[w_->length()].second.end())
                lpg_[w_->length()].second[suffix_] = unordered_set<string>();
            lpg_[w_->length()].first[prefix_].insert(suffix_);
            lpg_[w_->length()].second[suffix_].insert(prefix_);
        }
        else{
            ULONG plen_ = (ULONG)floor(w_->length() / 2);
            string pkey_ = prefix_;
            if(w_->length() != 1)
                prefix_ += w_->operator[](plen_ + 1);
            if(lpg_[w_->length()].first.find(pkey_) == lpg_[w_->length()].first.end())
                lpg_[w_->length()].first[pkey_] = unordered_set<string>();
            if(lpg_[w_->length()].second.find(suffix_) == lpg_[w_->length()].second.end())
                lpg_[w_->length()].second[suffix_] = unordered_set<string>();
            lpg_[w_->length()].first[pkey_].insert(suffix_);
            lpg_[w_->length()].second[suffix_].insert(prefix_);
        }
```

```
    }
}

string SpellChecker::_getPrefix(string s) {
    if(s.length() < 2)
        return s;
    ULONG plen_ = (ULONG)floor(s.length() / 2);
    return s.substr(0, plen_);
}

string SpellChecker::_getSuffix(string s) {
    if(s.length() < 2)
        return s;
    ULONG plen_ = (ULONG)floor(s.length() / 2);
    if(s.length() % 2)
        return s.substr(plen_, s.length() - plen_);
    return s.substr(plen_ + 1, s.length() - plen_ - 1);
}

#endif //CHW_2_SPELLCHECKER_H
```

3.4 Дополнительная функциональность

Дополнительная функциональность реализации отсутствует.

3.5 Заключение

В третьей части нами было исследовано влияние эффективности использования разных видов контейнеров для поиска замены ошибочных слов и написана программа, решающая данную задачу. Было выяснено, что красно-черные деревья, реализованные внутри set, имеют одну и ту же сложность по времени в лучшем, худшем и среднем случае. Хэш-таблицы, реализованные в unordered_set, имеют сложность по времени лучшем, чем красно-черные деревья, при условии отсутствия возникших коллизий. Но как было уже выявлено в заключении к первой части, вероятность коллизий достаточно мала и стремится к нулю.

СПИСОК ИСПОЛЬЗОВАННОЙ ЛИТЕРАТУРЫ

1. Wikipedia. Hash table [Электронный ресурс] //URL: https://en.wikipedia.org/wiki/Hash_table (Дата обращения: 11.05.2016, режим доступа: свободный).
2. Habrahabr. Trie, или нагруженное дерево [Электронный ресурс] //URL: https://habrahabr.ru/post/111874/ (Дата обращения: 11.05.2016, режим доступа: свободный).
3. C++ Reference. Set [Электронный ресурс] //URL: http://www.cplusplus.com/reference/set/set/ (Дата обращения: 11.05.2016, режим доступа: свободный).
4. C++ Reference. Unordered set [Электронный ресурс] //URL: http://www.cplusplus.com/reference/unordered_set/unordered_set/ (Дата обращения: 11.05.2016, режим доступа: свободный).
5. C++ Reference. Unordered map [Электронный ресурс] //URL: http://www.cplusplus.com/reference/unordered_map/unordered_map/ (Дата обращения: 11.05.2016, режим доступа: свободный).
6. Wikipedia. Standatd Template Library [Электронный ресурс] //URL: https://en.wikipedia.org/wiki/Standard_Template_Library (Дата обращения: 11.05.2016, режим доступа: свободный).
7. Wikipedia. Red-black tree [Электронный ресурс] //URL: https://en.wikipedia.org/wiki/Red–black_tree (Дата обращения: 11.05.2016, режим доступа: свободный).
8. Wikipedia. PATRICIA tree [Электронный ресурс] //URL: https://en.wikipedia.org/wiki/Radix_tree (Дата обращения: 11.05.2016, режим доступа: свободный).

Я, Ярных Роман Вячеславович, подтверждаю, что предоставляемое на проверку Домашнее задание по дисциплине «Алгоритмы и структуры данных» (модуль 4, 2015-2016 учебного года) выполнено мною самостоятельно. Данный отчет не содержит объяснений (пояснительного текста), фрагментов псевдокода и/или кода программ, взятых из других работ (электронных или печатных), без указания в тексте явных ссылок на эти источники.

Я проинформирован и полностью осознаю, что при обнаружении в отчёте факта списывания, подлога, плагиата и пр., моей оценкой за домашнее задание будет 0 (нуль) и ко мне будут применены меры, изложенные в документе *«Порядок применения дисциплинарных взысканий при нарушениях академических норм в написании письменных учебных работ в НИУ-ВШЭ»* (http://www.hse.ru/studyspravka/loc).